Revista de Administración, Finanzas y Economía (*Journal of Management, Finance and Economics*), vol. 2, núm. 2 (2008), pp. 125-135.

Teoría de matrices aleatorias y correlación de series financieras: El caso de la Bolsa Mexicana de Valores

Linda Margarita Medina Herrera[*]
Ricardo Mansilla Corona[**]

6 de febrero 2007, Aceptado 1 de julio 2008

Resumen

En este artículo aplicamos la teoría de matrices aleatorias (TMA) al análisis de una matriz de correlación C formada con los rendimientos diarios de 65 acciones comercializadas en la Bolsa Mexicana de Valores en un periodo de 8 años. Encontramos que las estadísticas de la mayoría de los valores propios en el espectro de C coinciden con las predicciones de la TMA, pero que hay desviaciones para algunos de los valores propios más grandes. Demostramos que C satisface las propiedades universales del conjunto gausiano ortogonal de matrices aleatorias. Más aún, analizamos los vectores propios de C a través de su cociente inverso de participación, tal análisis nos permite señalar que la matriz C tiene una estructura de banda aleatoria.

Abstract

In this paper we apply random matrix theory (RMT) to the analysis of cross-correlation matrix C constructed from daily returns of 65 stocks traded at the Bolsa Mexicana de Valores during a 8-year trading period. We find that the statistics of most of the eigenvalues in the spectrum of C agrees with the prediction of RMT, but there are deviations for a few of the larger eigenvalues. We show that C has the universal properties of the Gaussian orthogonal ensemble of random matrices. Furthermore, we analyze the eigenvectors of C through their inverse participation ratio, such analysis allow us to indicate matrix C has a random band structure.

Clasificación JEL: : C16,C65, G11

Palabras clave: Matrices aleatorias, matrices de correlación financieras

[*] Departamento de Matemáticas, Tecnológico de Monterrey, Campus Ciudad de México, Calle del Puente 222, Oficinas 1, Piso 2, Col. Ejidos de Huipulco, Del. Tlalpan, 14380 México, D.F., Teléfono +52(55)54832191, E-mail: linda.medina@itesm.mx

[**] Centro de Investigaciones Interdisciplinarias. Torre II de Humanidades, 4to piso.UNAM, Mexico 04510 D.F. E-mail: mansy@servidor.unam.mx

1. Introducción

Cuantificar la correlación entre diferentes variables es un tópico de interés necesario no solo para entender la economía como un sistema dinámico complejo, sino también por razones más prácticas como la administración de riesgos y la asignación de activos.

El estudio de matrices de correlación tiene una historia larga en finanzas y es una piedra angular de la teoría de optimización de portafolios de Markowitz, sin embargo, es difícil determinar de una manera confiable una matriz de correlación empírica.

Si se tienen N acciones con precio $P_i(t)$ para el activo i en el tiempo t, con, $t = 0, 1, \ldots, T$, el logaritmo de los rendimientos de los activos $S_i(t)$ es:

$$S_i(t) = \ln P_i(t) - \ln P_i(t-1).$$

Puesto que los niveles de volatilidad (desviación estándar) son diferentes para cada activo, se define el rendimiento normalizado

$$g_i(t) = \frac{S_i(t) - \langle S_i(t) \rangle}{\sigma_i}.$$

Donde σ_i es la desviación estándar de S_i y $\langle \cdot \rangle$ la media. Los elementos de la matriz de correlación empírica C son

$$C_{ij} = \frac{1}{T} \sum_{t=1}^{T} g_i(t) g_j(t).$$

La dificultad para construir una matriz de correlación empírica confiable se debe a varias razones, entre las cuales se encuentran:

- Las condiciones del mercado cambian con el tiempo y la correlación que existe entre un par de activos puede no ser permanente.
- La longitud de las series de tiempo disponible para estimar la correlación es finita y por lo tanto puede generar información falsa (ruido).

Por esto, la forma en que se mide la correlación empíricamente contiene contribuciones aleatorias, y en general es un problema difícil poder estimar de C la correlación que no es producto de la aleatoriedad. En particular, se ha demostrado que los valores propios más pequeños de la matriz C son los más sensibles al ruido, sus correspondientes vectores propios son precisamente aquellos que determinan los portafolios menos riesgosos [Laloux]. Es esta la razón por la cual los métodos que permiten distinguir señales de ruidos, esto es, diferenciar los valores y vectores propios que contienen información real, de aquellos que contienen información inútil o inestable en el tiempo, han adquirido una gran importancia.

Con este fin, es importante comparar las propiedades de una matriz de correlación C contra la "hipótesis nula" de una matriz de correlación aleatoria, esto es una matriz de correlación construida con series de tiempo de activos estrictamente independientes. Si las propiedades de C se asemejan a aquellas de la matriz de correlación aleatoria, entonces se sigue que el contenido de la matriz C es aleatorio. Recíprocamente, si las propiedades de las dos matrices difieren,

la correlación es genuina. Asípues, la meta es comparar las propiedades de una matriz empírica C con las de una matriz de correlación aleatoria y separar el contenido de C en dos grupos: la parte de C que tiene propiedades semejantes a las de la matriz aleatoria ("ruido") y la parte de C que difiere de la matriz aleatoria ("información").

En este trabajo examinaremos una matriz de correlación C construida a partir de las series de tiempo de las principales acciones que cotizan en la Bolsa Mexicana de Valores (BMV) con el objetivo de separar la información real del ruido y usaremos el concepto de "cociente inverso de participación" (CIP) para analizar los vectores propios que contienen más información.

1.1 Antecedentes

El estudio de las propiedades estadísticas de las matrices aleatorias tiene sus orígenes históricos en la física nuclear. El problema data de los años cincuenta; los modelos existentes no explicaban de manera adecuada los niveles de energía de un núcleo complejo. La Teoría de Matrices Aleatorias (TMA) desarrollada en ese contexto fue presentada por Wigner, Dyson y Mehta. Estudios recientes han mostrado que estos resultados tienen aplicaciones importantes en el contexto financiero.

Stanley, Amaral y otros (1999) usan la metodología de TMA para analizar la correlación cruzada entre los precios de las acciones de New York Stock Exchange, American Stock Exchange y de Nasdaq. Potters, Cizeau y Laloux (2002) muestran que los resultados de la TMA son de gran interés para entender la estructura estadística de las matrices de correlación empíricas; usando series de tiempo de diferentes acciones de S& P500, encuentran que hay una similitud importante entre las predicciones teóricas (basadas en que la matriz de correlación es aleatoria) y los datos empíricos. En este mismo artículo Potters, Cizeau y Laloux muestran que este método puede ser implementado en la administración de riesgos. Maslov (2001) utiliza la TMA para medir la globalización usando la matriz de correlación de los índices de mercado de 37 países, mostrando que hay fuertes interacciones entre las economías individuales. Burda, Gorlich, Jarosz y Jurkiewicz (2004) determinan, usando la TMA, una relación exacta entre el espectro de los valores propios de la matriz de correlación y sus estimaciones.

Estos estudios muestran que un porcentaje alto de los vectores propios de C coinciden con las predicciones de la TMA, sugiriendo que hay un alto grado de aleatoriedad en la medición de la correlación y que alrededor de un 2% de los vectores propios están por encima de las predicciones de la TMA.

Lo que nos lleva a preguntarnos en el caso mexicano cómo podemos interpretar los valores y vectores propios que se desvían de la predicción de la TMA? Qué se puede inferir acerca de la estructura de nuestra matriz C de estos resultados?

Referente a estas preguntas, veremos que el vector propio más grande de C representa la influencia de todo el mercado que es común a todos los activos del estudio. Nuestro análisis del contenido del resto de los vectores propios que difieren de TMA muestra correlaciones entre activos del mismo sector económico y las 32 acciones que tienen las mayores capitalizaciones en el mercado. Para probar que los vectores propios que se desvían de las predicciones de la TMA son los únicos que contienen información genuina de C, comparamos las propiedades

estadísticas de los vectores propios de C con las propiedades universales de las matrices reales, simétricas y aleatorias, y encontramos un muy buen ajuste con los resultados de la TMA. El cociente inverso de participación alcanza valores importantes en los extremos del espectro de los valores propios, sugiriendo una estructura de "banda aleatoria" para la matriz C.

2. Predicciones de la Teoría de Matrices Aleatorias (TMA)

El conjunto más simple de matrices aleatorias es el conjunto de matrices simétricas $\mathbf{R}$ de tamaño $N \times N$, cuyos elementos son variables aleatorias independientes e idénticamente distribuidas. Este conjunto de matrices es conocido como matices aleatorias Wishart o el conjunto Laguerre de la TMA [Mehta]. En notación matricial $\mathbf{R}$ se puede escribir como $\mathbf{R} = \frac{1}{N}\mathbf{A}\mathbf{A}^{\mathbf{T}}$, donde $\mathbf{A}$ es una matriz de tamaño $N \times T$ y $\mathbf{A}^{\mathbf{T}}$ es la matriz transpuesta de $\mathbf{A}$.

2.1 Predicciones de la TMA sobre el comportamiento de los valores propios

Un resultado interesante se obtiene cuando la matriz $\mathbf{R}$ tiene un tamaño muy grande ($N \to \infty$), en este caso la distribución de sus valores propios tiene propiedades universales, que son independientes de la distribución de los elementos de la matriz. Para el caso $N \neq T$ existe una formula [Mehta] para la densidad $\rho(\lambda_i)$ de los valores propios λ_i de $\mathbf{R}$. En el límite $N, T \to \infty$, con un cociente fijo $Q = \frac{T}{N} \geq 1$, se tiene:

$$\rho(\lambda_i) = \frac{Q}{2\pi\sigma_i^2}\frac{\sqrt{(\lambda_- - \lambda_i)(\lambda_i - \lambda_+)}}{\lambda}, \quad \lambda_i \in [\lambda_-, \lambda_+].$$

Donde λ_-, el valor propio más pequeño y λ_+, el valor propio más grande satisfacen

$$\lambda_\pm = \sigma^2\left(1 + \frac{1}{Q} \pm 2\sqrt{\frac{1}{Q}}\right) \tag{1.2}$$

es $\frac{\sigma^2}{T}$ la varianza de los elementos de $\mathbf{A}$, o de manera equivalente σ^2 es el promedio de los valores propios de $\mathbf{R}$.

La ecuación (1.2) da una medida estrictamente cuantitativa para decidir cuándo un valor propio particular de una matriz de correlación empírica $\mathbf{C}$ refleja una señal de correlación real presente en los datos, o si es simplemente un efecto de ruido causado en particular por la finitud T de la serie de datos. En principio, cualquier valor propio que sea significativamente mayor que λ_+ debe ser tratado como una señal.

Para aceptar o rechazar la hipótesis de aleatoriedad de una matriz $\mathbf{C}$ no es suficiente comparar la distribución de los valores propios de $\mathbf{C}$ con $\rho(\lambda_i)$. Hay matrices aleatorias que tienen unas diferencias drásticas en la distribución de los valores propios que comparten una estructura similar de correlación en sus valores propios debida únicamente a la simetría de las matrices. Por otra parte, matrices con la misma distribución de sus valores propios tienen diferencias drásticas en la correlación de los valores propios. Asípues, una prueba de aleatoriedad de $\mathbf{C}$ debe involucrar una investigación de la correlación en los valores propios λ_α.

Sea $\mathbf{S}$ una matriz real, aleatoria y simétrica de tamaño $M \times M$ cuyos elementos fuera de la diagonal $\mathbf{S_{ij}}$ con $i < j$ son independientes e idénticamente distribuidos. Se ha conjeturado, basado en evidencias analíticas y numéricas extensivas [Plerou] que en el límite $M \to \infty$, sin considerar la distribución de los elementos $\mathbf{S_{ij}}$, esta clase de matrices presenta las propiedades universales (funciones de correlación de los valores propios) del conjunto de las matrices cuyos elementos están distribuidos de acuerdo a una medida de probabilidad Gausiana llamado el conjunto gausiano ortogonal o simplemente GOE (de sus siglas en inglés Gaussian ortogonal ensemble) [Mehta].

Las pruebas estadísticas para los valores propios de $\mathbf{C}$ que se deben usar, son precisamente las pruebas universales de correlación de los valores propios de matrices aleatorias reales simétricas.

En resumen, las propiedades universales de las matrices GOE son:

1. La distribución de las diferencias de los valores propios de acuerdo al vecino más cercano $S \equiv \xi_{k+1} - \xi_k$ está dada por la ecuación:

$$P_{GOE}(S) = \frac{\pi S}{2} \exp\left(-\frac{\pi}{4} S^2\right)$$

donde $\xi_k = f(\lambda_k)$ es una transformación que convierte los valores propios λ_i en nuevas variables llamadas "valores propios desplegados" [Mehta]. Los valores propios desplegados tienen un valor promedio uniforme a través del espectro. A menudo se refieren a esta distribución como "la conjetura de Wigner".

2. La distribución de las diferencias de los valores propios de acuerdo al siguiente vecino más cercano $u = \xi_{k+2} - \xi_k$ es:

$$P_{GSE}(u) = \frac{2^{18}}{3^6 \pi^3} S^4 \exp\left(-\frac{64}{9\pi} u^2\right).$$

3. Correlaciones entre valores propios de rango largo.
Para probar correlaciones entre pares de valores propios en rangos largos, se usará el estadístico $\sum^2$ conocido como "varianza número", que está definido como la varianza del número de valores propios desplegados en intervalos de longitud l alrededor de cada ξ_i

$$\sum^2 \equiv \left\langle [n(\xi, l) - l]^2 \right\rangle_\xi$$

donde $n(\xi, l)$ es el número de valores propios desplegados en el intervalo $[\xi - 1/2, \xi + 1/2]$ y $\langle\rangle_\xi$ es el promedio sobre todos los ξ. Si los valores propios no están correlacionados, $\sum^2 \approx l$. En el extremo opuesto, cuando el espectro de los valores propios es rígido, $\sum^2$ es una constante. En las matrices aleatorias, para valores largos de l, la varianza número $\sum^2$ tiene un comportamiento intermedio $\sum^2 = \ln l$.

Es importante notar que estas tres propiedades son independientes entre si.

2.2 Predicciones de la TMA sobre el comportamiento de los vectores propios

Después de analizar el comportamiento de los valores propios, las conclusiones más importantes se obtendrán del estudio de las componentes de los vectores propios. Los componentes $\{u_l^k; l = 1, \ldots, N\}$ del vector propio u^k de una matriz aleatoria de correlación R están distribuidos normalmente con media cero y varianza uno.

Para cuantificar el número de componentes que participan significativamente en cada vector propio, se usará el cociente inverso de participación (CIP), una noción aplicada a menudo en la teoría de localización.

El CIP de un vector propio normalizado u^k está definido como

$$I^k = \sum_{l=1}^{N} \left(u_l^k\right)^4.$$

Donde N es el número de series de tiempo (empresas en nuestro caso) y por lo tanto el número de componentes. La $i-$ésima componente u_i^k del vector u^k corresponde a la contribución de la $i-$ésima serie de tiempo a tal vector propio.

Es importante notar que si todas las componentes son idénticas y $u_l^k = 1/\sqrt{N}$ se tiene que $I^k = 1/N$; si sólo hay una componente diferente de cero $u_l^k = 1$, $I^k = 1$. De esta manera, el CIP es el recíproco del número de componentes del vector que contribuyen significativamente al mismo.

3. Construcción y análisis de la matriz C

Las series de tiempo que conforman la base de datos para este estudio están formadas por los precios de cierre diario de 65 empresas que cotizan en la BMV, en un periodo de 8 años. Para la elección de las empresas y la longitud de la serie se tuvo en cuenta la bursatilidad, capitalización y mantenimiento de las mismas. La longitud final de las series es de 1598. Dentro de las 65 empresas seleccionadas para el estudio se encuentran representados todos los sectores económicos, las empresas elegidas tienen la mayor bursatilidad de cada sector y juntas representan más del 85% de participación en el IPC y el 100% del índice México (INMEX). Todas las acciones incluidas han permanecido activas en el periodo seleccionado para el estudio.

Ahora, queremos comparar las distribuciones empíricas de los valores propios y las estadísticas de los vectores propios de la matriz C construida a partir de estos datos con sus predicciones teóricas, asumiendo que la matriz de correlación es puramente aleatoria.

Tenemos, pues, $N = 65$ acciones con precio $P_i(t)$ para la acción i en el tiempo t, con $t = 0, 1, \ldots, 1598$. Después de considerar el logaritmo de los rendimientos de los activos y estandarizar cada una de las series, se calcula la matriz de correlación estandarizada C_{ij} que tiene un tamaño de 65×65.

El valor $Q = \frac{T}{N} = \frac{1597}{65} = 24.57 > 1$ garantiza que la matriz de correlación es definida positiva y permitirá la aplicación de la TMA. Además, $\lambda_+ = 1.4441$ y $\lambda_- = 0.63720$.

En el histograma de la distribución de los valores propios de C (Figura 1) se puede observar que tres valores propios se alejan visiblemente del grueso del

espectro. Estos tres valores propios son mayores que λ_+. La teoría asegura que si la matriz satisface las propiedades universales de la TMA, se podrá obtener información sustancial de estos tres valores propios. Hay también una cantidad importante de valores propios por debajo de λ_-, que de acuerdo a la literatura, son más susceptibles al ruido. Los valores entre $[\lambda_-, \lambda_+]$ representan la parte de la matriz sin información alguna.

Las diferencias entre las distribuciones empírica y teórica que se muestra en Figura 2 se deben precisamente a la existencia de valores propios por encima de λ_+ y por debajo de λ_-. Si la matriz C fuera completamente aleatoria, las dos curvas coincidirían y no se tendría información relevante. En la intersección de las dos curvas se encuentran los valores propios del intervalo $[\lambda_-, \lambda_+]$. Los valores propios por encima de λ_+, que contienen información real, están a la derecha de la curva roja, en azul. Y se puede ver que hay una cantidad importante de valores propios por debajo de λ_- en el intervalo $(0, \lambda_-]$. 24 valores propios están por debajo de $[\lambda_-$, 38 en el intervalo (λ_-, λ_+) y 3 son mayores que λ_+ (los tres rectángulos que se ven separados en la Figura 1).

El valor propio más grande 14.166 es más de 9 veces mayor que λ_+, se puede entonces atribuirle información real. El segundo mas grande valor propio 3.13 es mas del doble de λ_+, también proporcionará información importante, el siguiente valor propio 1.8615 es apenas un poco mayor que λ_+ sin embargo es posible hallar en el información importante.

Es indispensable recordar que la información que se puede obtener del espectro sólo será válida si se prueba que los valores propios que pertenecen al intervalo $[\lambda_-, \lambda_+]$ satisfacen las propiedades universales de la TMA. Después de transformar los valores propios en $\xi = f(\lambda_i)$ con el desplegado, se obtienen los siguientes resultados para la matriz C:
Las Figuras 2.3, 2.4 y 2.5 muestran que las gráficas de las distribuciones teóricas se ajustan muy bien a las empíricas. La hipótesis de la igualdad de las distribuciones es confirmada por el resultado de la prueba de bondad de ajuste de Kolmogorov-Smirnov. Permitiéndonos concluir que el espectro de C satisface las dos primeras propiedades universales de la TMA.

La tercera propiedad se cumple al analizar la Figura 2.6. A medida que l aumenta, $\sum^2$ se acerca a la función $\ln l$, esto es justamente lo que sucede en el espectro de las matrices aleatorias.

El primer resultado interesante es que todas las componentes del vector propio asociado al mayor valor propio son positivas, lo que significa que no hay acciones con correlación inversa. Puesto que los vectores propios correspondientes a valores propios diferentes son ortogonales entre ellos, otros vectores propios contienen componentes negativas. El vector propio asociado al mayor valor propio u^{65} tiene fuertes componentes en WalmexC, GFBBB, Cemex CPO, GcarsoA1, Televisa CPO, TV Azteca CPO y TelmexL. Las componentes más pequeñas corresponden a Cid Mega Resort, y Sab.

Al analizar los otros dos vectores propios que se desvían de RMT u^{64} y u^{63} se encuentra que las componentes significativas pertenecen a industrias similares o relacionadas. El vector propio u^{64} está dominado significativamente por empresas de comunicación: Telmex , CEL y Telecom A1 con componentes negativas. En el vector propio u^{63} dominado por empresas de comercio, se encuentra que las componentes negativas significativas corresponden a Waltmart, Soriana y Elektra mientras que las positivas corresponden a Herdez y Gigante.

En cuanto a los vectores propios correspondientes a los valores propios más pequeños, se encuentra que están localizados, esto es, dan información de una sola empresa: la líder en su sector. Por ejemplo, la mayor componente de u^1 corresponde a Telmex con $C_{ij} = 0.87291$, la mayor correlación de la muestra. Las mayor componente de u^2 es Walmex con $C_{ij} = 0.85832$, la segunda mayor correlación de la muestra.

El cociente inverso de participación (CIP) ayuda a cuantificar el número de componentes que participan significativamente en cada vector propio.

La Figura 2.7 muestra el cociente inverso de participación (CIP) I^k como una función de los valores propios λ_k de la matriz C. La región en el rectángulo rojo muestra el intervalo $[\lambda_+, \lambda_-]$.

Se puede decir que prácticamente los valores en intervalo $[\lambda_+, \lambda_-]$ permanecen en una banda o rango (el recuadro rojo), mientras que el CIP mínimo se obtiene en el valor propio más grande y los valores de CIP más altos, corresponden a los valores propios más pequeños. I^{65} tiene un valor de 0.024, si todas las componentes fueran iguales a $\frac{1}{\sqrt{N}} = \frac{1}{\sqrt{65}}$, el cociente sería 0.015 el cual representaría la influencia de todo el mercado. El hecho de que algunas componentes dominen este vector da una idea de las empresas líderes en el mercado y justifica el hecho de que el cociente de participación inverso sea mayor que 0.015. El vector propio u^{65} contiene aproximadamente $1/I^{65} = 40$ participantes significativos, que son precisamente las acciones con mayor capitalización en el mercado.

En la grafica se observa que el cociente de participación inverso de los valores propios menores que λ_- son considerablemente mayores, de hecho son de tres a cinco veces el promedio del CIP, lo que sugiere que los vectores están localizados, esto es, solo algunas acciones contribuyen a ellos. Por ejemplo el vector propio u^1 contiene $1/I^1 = 2$ acciones que contribuyen a el: Telmex A y L.

Este mismo estudio se realizó en matrices construidas a partir de series de longitud 400 y 800, encontrándose que dichas matrices no cumplían las propiedades universales de las matrices aleatorias.

4. Conclusiones

Se ha encontrado que la mayoría de los valores propios en el espectro de la matriz de correlación C coinciden notablemente bien con las predicciones universales de la Teoría de Matrices Aleatorias. En particular, se ha encontrado que la matriz C satisface las propiedades universales del conjunto gaussiano ortogonal de matrices simétricas aleatorias, lo cual nos permite distinguir los valores y vectores propios de la matriz que contienen información real de aquellos que tienen información inútil e inestable en el tiempo.

La matriz tiene 3 valores propios mayores que λ_+, 24 valores propios están por debajo de λ_- y 38 en el intervalo (λ_-, λ_+). El cociente inverso de participación soporta la idea de que algunas acciones dominan el mercado y más especficamente nos dice que el vector propio u^{65} contiene aproximadamente $1/I^{65} = 40$ participantes significativos, que son precisamente las acciones con mayor capitalización en el mercado. Tal parece que las componentes del valor propio más grande pueden ayudar en la elección de las empresas y los pesos de las mismas en la construcción de un índice. Los vectores propios correspondientes a los valores propios más pequeños están localizados, esto es cada

Figuras

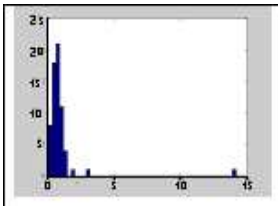


Figura 1 Distribución de los valores propios de C.

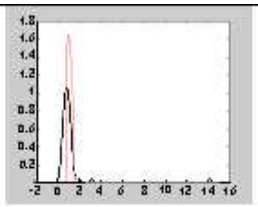


Figura 2 Distribución de los valores propios de C (---) y de la distribución teórica $P_{rm}(\lambda)$ (---).

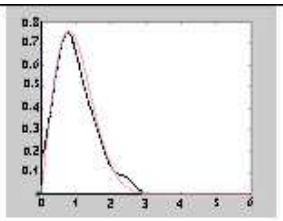


Figura 3 Distribución de $s_i = \xi_i - \xi_{i-1}$ empírica (----) y teórica (----)

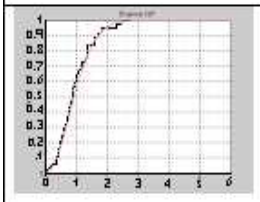


Figura 4 Distribución acumulada F_{GDE} (----) y la distribución acumulada de S (----)

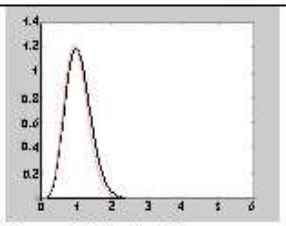


Figura 5 Distribución de $U = \xi_{k+2} - \xi_k$ empírica S (---) y teórica (---).

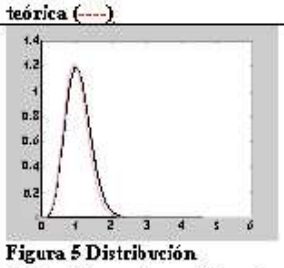


Figura 5 Distribución de $U = \xi_{k+2} - \xi_k$ empírica S (----) y teórica (----)

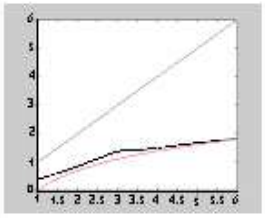


Figura 6 Estadístico varianza número $\Sigma^2(l)$ (---) aproximándose a la función $g(l) = \ln(l)$ (---) y alejándose de $f(l) = l$ (—).



Figura 7 Cociente inverso participación (CIP) La región en el rectángulo rojo muestra el intervalo $[\lambda_+, \lambda_-]$.

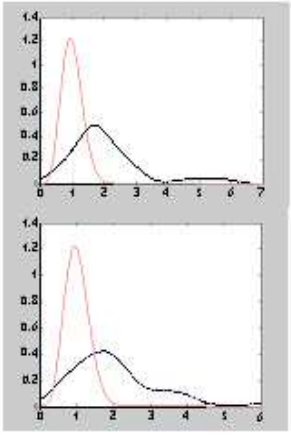


Figura 8 Arriba distribución de los valores propios de C_1 (----) y de la distribución teórica $P_{rm}(\lambda)$ (---) Abajo distribución de los valores propios de C_2 (----) y de la distribución teórica $P_{rm}(\lambda)$ (----).

uno de ellos da información de una empresa líder de un sector, por ejemplo u^1 está fuertemente dominado por Telmex. El análisis del CIP nos permite concluir que la matriz C tiene una estructura de banda aleatoria.

La longitud de las series (1598), entre otras cosas, ha permitido que la matriz C satisfaga las condiciones de la TMA. Pero se ha probado que para longitudes menores (800 y 400) las matrices C_1 y C_2 correspondientes no satisfacen todas las propiedades universales de la TMA (Figura 8).

Bibliografía

Bai, Z.D. (1999). Methodologies in Spectral Analysis of Large Dimensional Random Matrices, *A review. Statistica Sinica*, 9, 611-677.

Bouchaud, J.P., and Potters, M. (2003). *Theory of Financial Risks - From Statistical Physics to Risk Management-*. 2ed. Cambridge University Press, Cambridge.

Brody, T.A. Flores, J. French, J.P. Mello, P. Pandey, A.Wong, S. (1981) Random- Matrix Physics Spectrum and Strength Fluctuations. *Rev. Mod. Phys.*, 53, No. 3, 385-480.

Burda, Zdzislaw. Jurkiewicz, Jerzy (2004). Signal and Noise in Financial Correlation Matrices v2 e-print http://xxx.lanl.gov/cond-mat/0312496

Campbell, J. Lo, A. Mackinlay, A. (1997). *The Econometrics of Financial Markets*. Princeton University Press.

Fama, E. French, K. (1992). The Cross Section of Expected Share Returns, *J. Finance*, 47, 427-465.

Giada, L. Marsili, M. (2001). Data Clustering and Noise Undressing of Correlation Matrices. ıPhys. Rev. E, 63, 061101-

Gupta, A.K. Nagar, D. K. (2000). *Matriz Variate Distributions*. Chapman and Hall/CRG.

Kim, Dong-Hee. Jeong, Hawoong. (2005) Systematic Analysis of Group Identification in Stock Markets. . e-print. http://xxx.lanl.gov/physics/050 3076v1

Laloux, L. Cizeau, P. Bouchaud, Jean-Phillipe. Potters, Marc. (2002). Noise Dressing of Financial Correlation Matrices, *Phys. Rev. Lett.*, 83, 1467-1470.

Laloux, L. Cizeau, P. Bouchaud, Jean-Phillipe. Potters, Marc. (1999). *Random Matrix Theory and Financial Correlations. Mathematical Models and methods in applied sciences*. World Publishing company.

Mansilla, Ricardo (2003). Una breve introducción a la econofísica. Equipo Sirius.

Markowitz, H. (1959). *Portfolio Selection: Efficient Diversification of Investments*, Wiley, New York.

Marsili, M. (2002). Dissecting Financial Markets: Sectors and States. *Quantitative Finance*, 2, 297-302.

Maslov S. (2001). Measures of Globalization Based on Cross-Correlations of World Financial Indices, *Physica A*, 301, 397-406.

Medina, Linda (2005). *Un Nuevo método para la construcción de portafolios. El caso mexicano*. Tesis doctoral. Itesm. México.

Mehta, Madan (1991). *Random Matrices*. 2nd edition. Academic Press.

Plerou, V. Gopikrishnan, P. Rosenow, B. Amaral, L. Stanley, H.E. (1999). Universal and Nonuniversal Properties and Cross Correlations in Financial Time Series. *Phys. Rev. Lett.*, 83, 1471 -1474.

Rosenow, B. Plerou, V. Gopikrishnan, P. Stanley, H.E. (2003). Dynamics of Cross-Correlations in The Stock Market. *Physica A*, 324, 241-246

Sengupta, A.M. Mitra, P.P. (1999). Distribution of Singular Values for Some Random Matrices. *Phys.Rev. E*, 60, 3389-

Wang, Peijie (2004). Spectral Analysis of Economic Time Series Behaviour. JEL No: 22.